ESERCITAZIONE FINALE · MODULO 4

ToysGroup

Analisi dei dati di vendita con Python

Andrei George Ciobotaru

25 ottobre 2026

PUNTO DI PARTENZA

I dati che ho usato

File	Cosa contiene
`products.csv`	12 prodotti, in 3 categorie
`regions.xlsx`	9 stati e la regione di vendita
`sales.json`	2.000 vendite, con alcuni valori mancanti
`resellers.csv`	300 rivenditori, con l'indicazione del churn

> Il churn indica i rivenditori che non riordinano da oltre 6 mesi.

TASK 1

Python di base

- Pandas l'ho usato **solo per leggere i file**: il resto con Python normale.
- Ho messo i dati in **liste, dizionari e set**.
- Ho dato a ogni prodotto una fascia di prezzo (Bassa, Media, Alta) con una funzione.
- Con un ciclo ho calcolato il **fatturato per categoria**, uguale a quello del Task 3b.
- Con un ciclo **while** ho contato le transazioni per superare 10.000 €: ne servono **52**.

TASK 2

Lettura e controllo dei dati

- Ho letto i quattro file con Pandas (CSV, Excel e JSON).
- Ho guardato la struttura: righe, colonne e tipi di dato.
- Ho selezionato righe e colonne con **.loc** e **.iloc**.
- Ho usato **NumPy** per calcolare il prezzo unitario di tutte le vendite insieme.

> Una vendita vale in media 294,78 € e comprende in media 4,97 pezzi.

TASK 3A

Valori mancanti, filtri e ordinamenti

- Mancavano **100 valori in Quantity** e **100 in SalesAmount**.
- In Quantity ho messo la **mediana** (5).
- Le 100 righe senza importo le ho eliminate: restano **1.900 vendite**.
- Con le query ho trovato le vendite sopra il 90° percentile (756 €): **162 transazioni**.

TASK 3B

Unire e raggruppare le tabelle

- Ho collegato vendite, prodotti e regioni con **merge**.
- Ho raggruppato i dati con **groupby** per categoria e per stato.
- Ho separato le vendite del 2025 dalle altre e le ho rimesse insieme con **concat**.

Outdoor
categoria che fattura di più

Austria
stato che fattura di più

Centro Europa
regione di vendita più forte

TASK 3C

Date e andamento nel tempo

- Ho trasformato la colonna delle date con **to_datetime**.
- Ho ricavato anno e mese e calcolato il fatturato per periodo.
- Con **pct_change** ho misurato la crescita da un anno all'altro.

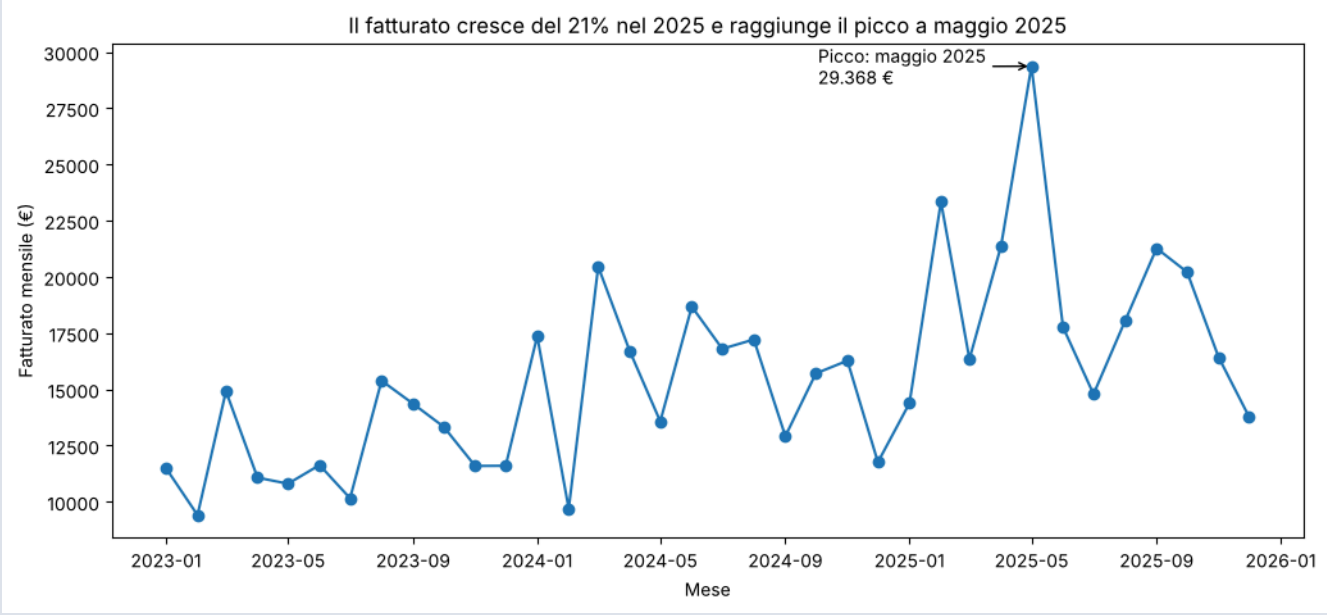
145.805 €
fatturato 2023

187.175 €
fatturato 2024

227.095 €
fatturato 2025 (+21%)

TASK 4

Grafici



- Ho usato **Matplotlib**, **Seaborn** e **Plotly**.
- Ogni titolo dice già il risultato.
- Il fatturato cresce nel 2025 e ha il **picco a maggio 2025** (29.368 €).

TASK 5

Correlazione e regressione lineare

- La coppia più legata è **fatturato e quantità**: correlazione 0,87.
- Ho provato una regressione semplice e una multipla sul fatturato mensile.

Modello	R^2 sui dati di allenamento	R^2 sui dati di test
Semplice	0,48	-1,88
Multipla	0,84	-0,42

> Sul test i risultati sono negativi: i dati sono pochi e i modelli non reggono bene. Il multiplo va meno peggio del semplice.

TASK 6A

Prevedere il churn

- Ho usato la **regressione logistica** per capire quali rivenditori rischiano di andarsene.
- Ho diviso i dati in allenamento e test e ho standardizzato le variabili.
- Ho confrontato due soglie: 0,5 e 0,3.

29%
rivenditori trovati con soglia 0,5

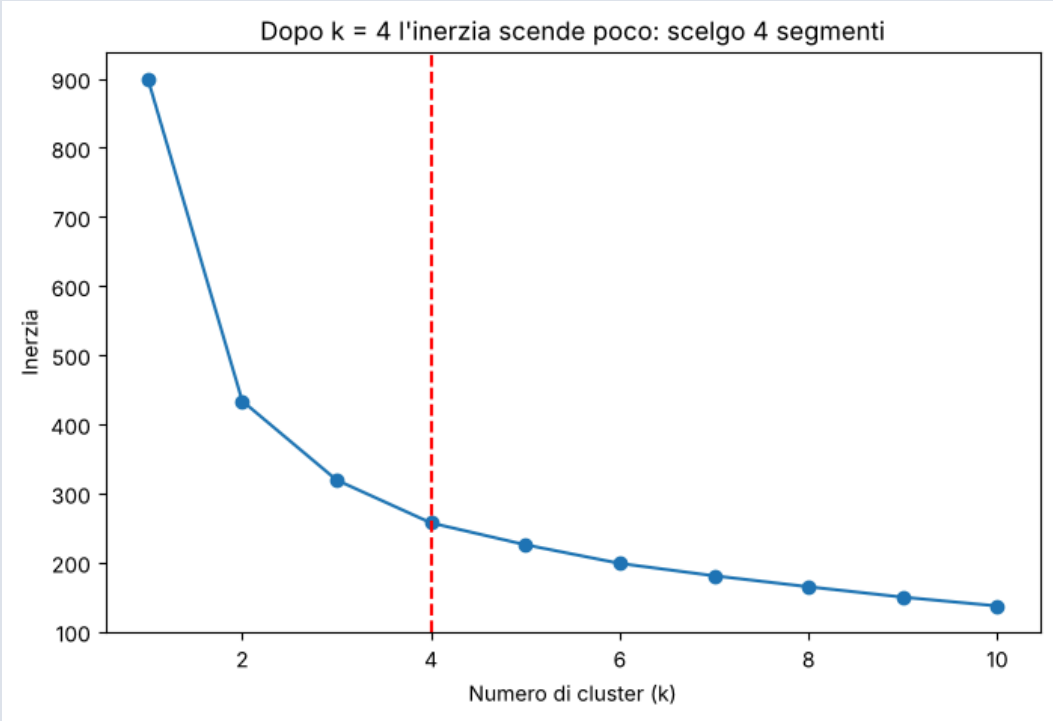
71%
rivenditori trovati con soglia 0,3

0,76
AUC del modello

> Ho scelto la soglia 0,3: preferisco trovare più rivenditori a rischio, anche con qualche falso allarme.

TASK 6B

Segmentare i rivenditori



- Con **K-Means** e il metodo del gomito ho scelto **4 gruppi**.
- Ho dato un nome a ogni gruppo.

Gruppo	Churn
Top rivenditori	6%
Regolari	8%
In raffreddamento	28%
A rischio	**51%**

TASK 7

Correggere il codice con un assistente AI

Caso	Il problema	La correzione
1	La media del fatturato esce NaN (valori mancanti)	Salto i valori mancanti: media 294,78 €, uguale a .mean()
2	Data leakage: la standardizzazione usa anche i dati del test	Prima divido train e test, poi standardizzo solo sul train
3	Uso **and** invece di **&** nel filtro	Uso **&** con le parentesi
4	Funzione poco leggibile, con colonne scelte per posizione	Nomi chiari, colonne per nome e una docstring

> Per ogni caso nel notebook ho scritto errore, causa, prompt usato e codice corretto.

IN SINTESI

Cosa ho scoperto

- Il fatturato **cresce del 21% nel 2025**, con il picco a maggio.
- Outdoor è la categoria che vende di più e l'Austria è lo stato migliore.
- Il churn dipende soprattutto dai **giorni dall'ultimo ordine**.
- Il gruppo di rivenditori «A rischio» ha il **51% di churn**: è da seguire per primo.

> Tutto il lavoro è nel repository GitHub, con notebook, dati, README e commit descrittivi.